Листок 7. Методы оптимизации

Градиентный спуск, выпуклость, Momentum/Nesterov, RMSprop/Adam и функции потерь.

1. **Градиентный спуск.** Рассмотрим функцию

$$f(x) = \frac{1}{2}(x-4)^2.$$

   Начальная точка $x_0 = 0$, шаг $\eta = 0{,}5$. Выполните два шага градиентного спуска. Найдите x_1, x_2 и значения $f(x_0)$, $f(x_1)$, $f(x_2)$.

2. **GD, SGD и mini-batch.** В текущей точке $w = 1$ градиенты функции потерь на четырёх объектах равны $2, 4, -2, 0$. Шаг $\eta = 0{,}1$. Найдите новую точку: а) для полного GD, используя средний градиент по всем четырём объектам; б) для SGD, если выбран первый объект; в) для mini-batch из первых двух объектов. Сравните величины трёх обновлений.

3. **Выпуклость.** Для функции $f(x) = x^2 - 6x + 10$ докажите выпуклость с помощью второй производной. Затем найдите точку минимума и минимальное значение функции. Объясните, почему найденный минимум является глобальным.

4. **Momentum.** Используется схема

$$v_t = \beta v_{t-1} - \eta g_t, \qquad x_t = x_{t-1} + v_t.$$

   Пусть $x_0 = 3$, $v_0 = 0$, $\beta = 0{,}5$, $\eta = 0{,}1$, а последовательные градиенты $g_1 = 4$ и $g_2 = 2$. Найдите v_1, x_1, v_2, x_2. Сравните второй шаг с обычным GD при том же g_2.

5. **Nesterov.** Для $f(x) = \frac{1}{2}x^2$ применяют

$$v_1 = \beta v_0 - \eta f'(x_0 + \beta v_0), \qquad x_1 = x_0 + v_1.$$

   Дано $x_0 = 2$, $v_0 = -1$, $\beta = 0{,}5$, $\eta = 0{,}2$. Найдите точку, в которой вычисляется градиент, затем v_1 и x_1. Для сравнения вычислите один шаг обычного Momentum, если градиент берётся в x_0.

6. **RMSprop.** Используется

$$s_t = \rho s_{t-1} + (1-\rho) g_t^2, \qquad \theta_t = \theta_{t-1} - \eta \frac{g_t}{\sqrt{s_t}}.$$

   Пусть $\theta_0 = 2$, $s_0 = 0$, $\rho = 0{,}75$, $\eta = 0{,}1$, ε можно считать равным нулю. Последовательные градиенты $g_1 = 2$ и $g_2 = 1$. Выполните два шага метода.

7. **Adam.** Пусть $\theta_0 = 1$, $m_0 = 0$, $q_0 = 0$, $g_1 = 2$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}99$, $\eta = 0{,}1$, $\varepsilon = 0$. Для первого шага вычислите m_1, q_1, исправленные оценки $\hat{m}_1$ и $\hat{q}_1$, а затем θ_1 по правилу

$$\theta_1 = \theta_0 - \eta \frac{\hat{m}_1}{\sqrt{\hat{q}_1}}.$$

8. **Функции потерь.** а) Для истинных значений $y = (1, 3)$ и прогнозов $\hat{y} = (2, 1)$ вычислите MSE. б) В бинарной классификации $y = 1$, модель выдала вероятность $p = 0{,}8$. Вычислите Log-loss. в) В задаче на 3 класса истинный класс — второй, а модель выдала вероятности $(0{,}1;\ 0{,}7;\ 0{,}2)$. Вычислите Cross-Entropy. г) Что произойдёт с Cross-Entropy, если вероятность истинного класса уменьшится с $0{,}7$ до $0{,}4$?