Теория к листку 7

Минимум, достаточный для решения всех 8 задач практического листка.

1. Градиентный спуск (задача 1)

Пусть минимизируем $L(\theta)$. Градиент показывает направление наибольшего роста, поэтому движемся в противоположную сторону:

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t).$$

$\eta > 0$ — learning rate (шаг). В одномерном случае $\nabla L = L'(x)$. Хорошая проверка: при разумном шаге значение функции обычно уменьшается.

2. GD, SGD, mini-batch (задача 2)

GD: градиент усредняется по всей выборке. SGD: используется один случайный объект. Mini-batch: усредняем градиент по небольшой группе объектов.

$$g_{\text{batch}} = \frac{1}{m} \sum_i g_i, \qquad \theta_{\text{new}} = \theta - \eta g_{\text{batch}}.$$

GD стабильнее, но дороже; SGD шумнее, но дешёвый; mini-batch — основной компромисс на практике.

3. Выпуклые функции (задача 3)

Для дважды дифференцируемой функции одной переменной достаточно проверить $f''(x) \geq 0$ на всей области. Если $f''(x) > 0$, функция строго выпукла. У выпуклой дифференцируемой функции любая точка, где $f'(x) = 0$, является глобальным минимумом. Для строго выпуклой функции такой минимум единственный.

4. Momentum (задача 4)

Momentum хранит «скорость» и добавляет к новому шагу часть предыдущего движения. Это сглаживает колебания и помогает быстрее двигаться в устойчивом направлении:

$$v_t = \beta v_{t-1} - \eta g_t, \qquad \theta_t = \theta_{t-1} + v_t.$$

Обычно $0 \leq \beta < 1$. При $\beta = 0$ получаем обычный градиентный спуск.

5. Nesterov (задача 5)

Nesterov сначала мысленно делает шаг по накопленной скорости, а градиент вычисляет в «точке взгляда вперёд»:

$$\text{lookahead} = \theta_{t-1} + \beta v_{t-1},$$

$$v_t = \beta v_{t-1} - \eta \nabla L(\text{lookahead}), \qquad \theta_t = \theta_{t-1} + v_t.$$

Отличие от Momentum: градиент берётся не в текущей точке.

6. RMSprop (задача 6)

RMSprop хранит экспоненциальное среднее квадратов градиентов. Если по координате градиенты долго большие, эффективный шаг по ней уменьшается:

$$s_t = \rho s_{t-1} + (1-\rho) g_t^2, \qquad \theta_t = \theta_{t-1} - \eta \frac{g_t}{\sqrt{s_t} + \varepsilon}.$$

Квадрат, корень и деление выполняются покоординатно.

7. Adam (задача 7)

Adam сочетает Momentum (среднее градиентов) и RMSprop (среднее квадратов градиентов), а также исправляет смещение в начале работы:

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t,$$

$$q_t = \beta_2 q_{t-1} + (1-\beta_2) g_t^2,$$

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \qquad \hat{q}_t = \frac{q_t}{1-\beta_2^t},$$

$$\theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{q}_t} + \varepsilon}.$$

8. Функции потерь (задача 8)

MSE — регрессия. Log-loss/Binary Cross-Entropy — бинарная классификация. Cross-Entropy — многоклассовая классификация.

$$\mathrm{MSE} = \frac{1}{n}\sum_i (y_i - \hat{y}_i)^2.$$

$$\mathrm{BCE} = -[y \ln p + (1-y)\ln(1-p)].$$

$$\mathrm{CE} = -\sum_k y_k \ln p_k.$$

Для one-hot метки $\mathrm{CE} = -\ln p_{\text{true}}$. Чем меньше вероятность истинного класса, тем больше CE.

9. Что помнить на вычислениях

Градиенты и скорости могут быть отрицательными — это нормально. В адаптивных методах знаменатель всегда неотрицателен. В Adam не забывайте bias correction на первых шагах. Для логарифмов здесь используется натуральный ln:

$$-\ln(0{,}8) \approx 0{,}223, \qquad -\ln(0{,}7) \approx 0{,}357, \qquad -\ln(0{,}4) \approx 0{,}916.$$