Теория к листку 9

Среднее, медиана, MSE и MAE

1. Среднее арифметическое

Для чисел $y_1, \dots, y_n$

$$\bar{y} = \frac{y_1 + \dots + y_n}{n}.$$

Среднее использует величину каждого наблюдения, поэтому один очень большой выброс может сильно его изменить.

Пример. Для $2, 3, 4, 5, 6$ среднее равно 4. Если добавить 30, то

$$\bar{y} = \frac{2+3+4+5+6+30}{6} = \frac{25}{3}.$$

2. Медиана

Сначала числа нужно отсортировать:

$$y_{(1)} \le y_{(2)} \le \dots \le y_{(n)}.$$

Если n нечётно, медиана — среднее по позиции число. Если n чётно, обычно берут среднее двух центральных:

$$\text{med}(y) = \frac{y_{(n/2)} + y_{(n/2+1)}}{2}.$$

Медиана зависит прежде всего от порядка, поэтому гораздо устойчивее к выбросам.

3. MSE

Для прогнозов $\hat{y}_i$ и истинных значений y_i

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2.$$

Если модель всегда выдаёт одно число c, то

$$L(c) = \frac{1}{n}\sum_{i=1}^{n}(c - y_i)^2.$$

Дифференцируем:

$$L'(c) = \frac{2}{n}\sum_{i=1}^{n}(c - y_i) = 2(c - \bar{y}).$$

Поэтому

$$\boxed{\text{MSE минимален при } c = \bar{y}.}$$

Квадрат сильно штрафует большие ошибки: ошибка 10 даёт вклад 100.

4. MAE

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|\hat{y}_i - y_i|.$$

Для постоянного прогноза c:

$$L(c) = \frac{1}{n}\sum_{i=1}^{n}|c - y_i|.$$

Если двигать c вправо, расстояния до точек слева увеличиваются, а до точек справа уменьшаются. Баланс достигается в середине отсортированной выборки. Поэтому

$$\boxed{\text{MAE минимален на медиане.}}$$

Если наблюдений чётное число, то любое c между двумя центральными значениями минимизирует сумму модулей:

$$c \in [y_{(n/2)}, y_{(n/2+1)}].$$

Главная пара для запоминания:

$$\boxed{\text{MSE} \longleftrightarrow \text{среднее}, \qquad \text{MAE} \longleftrightarrow \text{медиана}.}$$

5. Как это использовать для прямой $\hat{y} = ax + b$

Если в задаче всего два различных значения x, например $x = 0$ и $x = 2$, то числа

$$\hat{y}(0) = b, \qquad \hat{y}(2) = 2a + b$$

можно выбирать независимо: по двум желаемым значениям однозначно восстанавливаются a и b. Поэтому для каждой «вертикали» $x = c$:

- при MAE оптимальный прогноз на этой вертикали — медиана её y;
- при MSE оптимальный прогноз — среднее её y.

После этого восстанавливаем прямую по двум точкам.

6. Алгоритм на олимпиаде

1) Увидели квадрат ошибки — подумайте про среднее.
2) Увидели модуль ошибки — отсортируйте и подумайте про медиану.
3) Есть одинаковые x — сгруппируйте точки по вертикалям.
4) Нужно обосновать минимум MSE — возьмите производную.
5) Есть большой выброс — ожидайте, что MSE/среднее изменятся сильнее, чем MAE/медиана.